Proje bir bakışta

Ne yapıyoruz?

Bir büyük dil modeline (BDM, metin okuyan bir yapay zekâ modeli) hadis okutuyoruz. Model, isnaddaki (aktarım zincirindeki) ravileri, yani aktaran kişileri ve sıralarını öneriyor. Sabit kurallarla çalışan kontroller, kaynağın desteklemediği önerileri ayırıp inceleme kuyruğuna gönderiyor. Kuyruğa henüz gerçek bir kişi karar vermedi.

Bilgi grafında, kişileri ve aralarındaki bağlantıları tutuyoruz. Model buraya doğrudan yazamıyor. Kabul edilen her bilgi için kimin veya hangi adlı kuralın, ne zaman kabul ettiğini kaydediyoruz.

Savunduğumuz fikir

Dil modeliyle kurulan bilgi katmanında kişinin kararını saklamalıyız. Kaynaktan yeniden çıkarılabilen bilgiyi yeniden çıkarmalı, saklamamalıyız. Bu, proje sahibinin seçtiği iddia; henüz danışman onayı almadık. Ana kanıtı hadis motoruyla, destekleyici sınamaları kimlik kararları ve kod hakkında soru cevaplama çalışmalarıyla sunacağız.

Şimdiye kadar ne ölçtük?

Hadis çıkarımı sonuçlarını İfta adlı mevcut platformun etiketlerine göre ölçtük. Bunlar insanların hazırladığı bir doğru cevap anahtarı değil. Tek model kullandık: Claude Haiku 5.5. Hiçbir koşuda kişi karar vermedi.

Ölçüm	Sonuç
Altı koleksiyondan 300 hadis, esnek eşleştirmeyle F1	Kural tabanlı ayrıştırıcı: 0,923; yalnız şema verilen model: 0,890; tür açıklamaları ve alan ipuçlarıyla: 0,956
"Değer alıntıda mı?" kontrolü, yalnız şema verilen model	Etiketlerle uyuşmayan 145 önerinin 122'sini yakaladı (%84); 33 yanlış alarm verdi.
İncelemesiz kabul edilenlerde precision	Kontrol ile 0,914'ten 0,985'e çıktı.

F1, doğru bulduklarımızı ve kaçırdıklarımızı birlikte özetleyen puandır. Precision, kabul edilen önerilerin ne kadarının doğru olduğudur. Değer kontrolünün işaretlediklerinin çoğu uydurma ravi değildi; model adları Latin harfleriyle yazmış veya dil bilgisel biçimini değiştirmişti.

Hangi belgeler hazır?

Tez taslağımız 55, makale taslağımız 11 sayfa; ikisi de İngilizce ve Türkçe hazır. Gönderilmemiş TÜBİTAK 2209-A form taslağımız, son metni hazır CSE 491 proje önerimiz ve hadis uzmanı için bilgi notlarımız var. Danışmanımız bunların hiçbirini henüz okumadı.

Neler eksik?

İnsan etiketimiz ve insan incelemecimiz yok. Kimlik karar defteri yalnızca benzetimde var. Alan kurallarını motora eklemedik. Tek model denedik. Kaynak taramamız sistematik değildi.

Yahya Efe Kuruçay · Deniz Büyükşahin · Alperen Ulukaya · Danışman: Arş. Gör. Dr. Taha Yiğit Alkan

Başkaları ne yapmış

Hadis tarafı

Bu çalışmaları 8 ve 15 Ekim'de tam metinleriyle okuduk; aşağıda yalnız özetini okuduklarımızı ayrıca belirttik. "Bulamadık" dediğimiz özellikler, okuduğumuz metinlerde yoktu. Bilgi grafı, kişileri ve aralarındaki bağlantıları tutan yapıdır. F1, doğru bulunanlarla kaçırılanları birlikte özetleyen puandır.

Çalışma	Ne yapıyor?	Bizden farkı
SemanticHadith 2.0.1, Kamran, Butt ve Basharat (2026)	Altı koleksiyondan 34.458 hadisin bilgi grafını kuruyor. Dil modeli yerine özel eğitilmiş bir tanıyıcı kullanıyor. Üç uzman, koleksiyon başına rastgele 100 örneği kontrol etmiş.	Bilgi başına karar kaydı ve kaynak alıntısı kontrolü bulamadık. Aynı adı taşıyan kişileri işaretliyor veya dışarıda bırakıyor. Aday listesiyle uzmana sormayı gelecek çalışmaya bırakıyor. Biz kişinin kararını kaydedip yeniden kullanmayı sınayacağız.
Oumer (2025)	Özel eğitilmiş modeller, platform etiketlerine göre ravi F1'ında 0,98, ilişki F1'ında 0,95'e ulaşıyor. Sayılar yazarın model deposundan.	Çok sayıda etiketli eğitim verisine ihtiyaç duyuyor. Bizim iddiamız daha yüksek çıkarım puanı değil; önerinin kontrolü ve kişinin kararı.
AR-Sanad 280K, Mahmoud ve diğerleri (2022)	Ravi kimliğini belirliyor. Gerçek zincirlerde mikro F1 83,5; zincirlerin %60,6'sında en az bir yanlış ravi var.	Biz kimlik kararını hangi durumda yeniden kullanabileceğimizi sınayacağız. AR-Sanad v2 (2024) %94,6, Mosa (2025) %97,8 doğruluk bildiriyor; bunlar yapay zincirlerde ve yalnız özetlerini okuduk.
Rezwan (2025) ve Çinici (2026)	Hadis metinlerinde dil modeli kullanıyorlar. Değerlendirmeleri 0 ile 10 arası uzman puanları veya bir yazarın 100 kaydı sayısal sonuç vermeden kontrol etmesi biçiminde.	Biz aynı önerilerde her kontrolün ne yakaladığını insan etiketlerine göre ayrı ayrı ölçeceğiz.

Genel bilgi grafı tarafı

Okuma listemizdeki 27 makaleye, bir tarama yazısının işaret ettiği iki sistemi ekledik: toplam 29 çalışma. Dil modeli, metin okuyup öneri üreten yapay zekâ modelidir. Güven skoru, modelin kendi cevabına verdiği eminlik puanıdır.

Çalışma	Ne yapıyor?	Bizden farkı
Tsaneva ve diğerleri (2025), en yakın çalışma	Bilimsel bilgi grafını doğrulamak için dil modeli denetçileriyle insanları birleştiren dokuz iş akışı deniyor. İnsanlara bütün ilişkileri, az belgede geçenleri veya model denetçisiyle işlem hattının anlaşamadıklarını gösteriyor.	Yalnız anlaşmazlıkları insana gönderince F1, 75'ten 77 ile 79 arasına çıkıyor; 61 ile 75 arası insan kararı kullanılıyor. Modülleri tek başına değerlendirmediklerini yazıyorlar. Önceki otomatik denetçinin attığı ilişkilerin %34'ü doğruymuş. Biz kontrolleri ayrı ölçeceğiz.
KARMA (2025)	Birden çok dil modeli ajanıyla çalışıyor; doğrulama ajanlarını sırayla kaldırıp sonucu ölçüyor.	Sonucu dil modeli hakemi puanlıyor. Biz insan etiketlerini referans alacağız.
ODKE+ (Apple, 2025)	İkinci bir dil modeli, kaynağın her bilgiyi destekleyip desteklemediğini soruyor. %35 daha az uydurma bilgi ve %91'den %98,8'e çıkan precision bildiriyor. Precision, kabul edilenlerin doğru olan payıdır.	Nasıl ölçtüğünü açıklamıyor. Biz sabit kuralların etkisini dış referansla ölçeceğiz.

Çalışma	Ne yapıyor?	Bizden farkı
Knowledge Vault (Google, 2014)	Bilgiyi, doğrulukla uyumu ayarlanmış güven skoruna göre kabul ediyor. Doğruyla yanlışı ayırma ölçüsü AUC, otomatik etiketlerde 0,959, insan etiketlerinde 0,869.	Biz güven skoruyla kontrolü aynı inceleme payında karşılaştıracağız.
HoloClean (2017)	Düşük güvenli veri düzeltmelerini kullanıcıya sormayı öneriyor; bunu denemiyor.	Biz insan incelemesini ölçmeyi planlıyoruz.
Zep (2025)	Yeni bilgi eskiyle çelişince dil modeli eski bilgiyi geçersiz sayıyor.	Kararı kişi vermiyor. Biz kişinin kararını saklayıp yeniden kullanmayı sınayacağız.
GraphRAG (2024) ve Carriero ve diğerleri (2024)	Tasarımları gereği metinde kelimesi kelimesine bulunmayan çıktıları kabul ediyorlar.	Biz çıkarılan değerin modelin kendi alıntısında bulunmasını ayrı bir kontrol olarak ölçüyoruz.

Okuduğumuz 29 çalışmanın hiçbirinde çıkarılan değerin modelin kendi alıntısında bulunup bulunmadığı kontrolünü bulamadık; taramamız sistematik değildi.

Yahya Efe Kuruçay · Deniz Büyükşahin · Alperen Ulukaya · Danışman: Arş. Gör. Dr. Taha Yiğit Alkan

Farkı nerede ve nasıl ortaya koyacağız

Neyi iddia etmiyoruz?

Yeni şema (veri düzeni), daha yüksek çıkarım doğruluğu, belirsizliği insana sorma veya kaynak kaydetme fikrinin yeniliğini iddia etmiyoruz. Bilgi grafında (kişiler ve bağlantıları) kişinin kararını saklama, kaynaktan çıkarılabileni yeniden çıkarma iddiasını sınayacağız. Henüz danışman onayı almadık.

D1: Değer, alıntının içinde mi?

Dil modeli (metin okuyan yapay zekâ modeli) doğru bir alıntı verip içinde bulunmayan bir ad önerebilir. Temsili örnek: metinde "Süfyân" yazarken model "Süfyân b. Uyeyne" yazabilir. Alıntı doğrudur; önerilen değer içinde yoktur. Bunu ayrı hata türü olarak ölçüyoruz.

Yalnız şema verilen Claude Haiku 5.5 koşusunda kontrol, 1.688 ravi önerisinin 155'ini (%9,2) işaretledi. İfta platformunun etiketleriyle uyuşmayan 145 önerinin 122'sini (%84) yakaladı; 33 yanlış alarm verdi, 23 uyuşmazlığı kaçırdı. Etiketler insan cevap anahtarı değil; kişi karar vermedi. İşaretlenenlerin çoğu uydurma ravi değil, Latin harflerine çevrilmiş veya dil bilgisel biçimi değiştirilmiş doğru adlardı.

İnsan etiketleriyle bu ayrımı yeniden sayacağız.

D2: Her kontrol tek başına ne yakalıyor?

Aynı önerilerde kontrolleri ayrı ölçeceğiz. Buna ablation, yani parçaları çıkarıp katkılarını karşılaştırma diyoruz. Sonucu dil modeline puanlatmayacağız.

Model, Peygamber'i 10 kez ravi yazdı; değer kontrolü 2'sini yakaladı. Henüz eklemediğimiz "Peygamber ravi değildir" kuralı kalan 8'ini yakalardı.

İlahiyat alanından Prof. Dr. Rifat Atay, etiketleme kılavuzunu inceleyip açık soruları yanıtlayacak. Deniz ve Alperen, sistem çıktısını görmeden 50 hadisi bağımsız etiketleyecek. Uyumlarını karşılıklı F1 ile ölçeceğiz. F1, doğru bulduklarımızı ve kaçırdıklarımızı birlikte özetleyen puandır. Hadis başına süreyi kaydedeceğiz. Anlaşmazlıkları uzman karara bağlayacak.

D3: Modelin eminliğinden daha yararlı mı?

Güven skoru, modelin kendi cevabına verdiği eminlik puanıdır. Kontrolü bununla aynı inceleme payında karşılaştıracağız.

İfta etiketlerinde güven skoru 0,85'in altındakileri incelemeye göndermek, 275 öneriyi (%16,3) gönderip 145 uyuşmazlığın 50'sini yakalıyor. İnsan etiketli biyomedikal BC5CDR verisinde ise kontrol 303 uyuşmazlığın 53'ünü, aynı inceleme payındaki güven skoru 58'ini yakaladı. Kontrol her yerde daha iyi değil.

İnsan etiketli hadislerde aynı pay karşılaştırmasını yapacağız. O hadisi etiketlememiş bir ekip üyesi inceleme kuyruğuna karar verecek. Karar süresini, ret oranını ve işaretlenenlerin daha sık reddedilip reddedilmediğini ölçeceğiz. Kuyruğa uzman karar vermeyecek; cevap anahtarını belirleyen kişi sistemi puanlamayacak.

D4: Kişinin kararını yeniden kullanmak

Motor her kabul için karar veren kişiyi veya adlı kuralı ve zamanı kaydediyor. Ravi kimliği kararını yeniden kullanacak, nesil ve ölüm yılı kuralı çelişki bulursa geçerli olduğu alanı daraltacağız. Mekanizmanın yeni olduğunu iddia etmiyoruz; en yakın çalışma Zep'te kararı kişi yerine model veriyor.

AR-Sanad'ın 27.056 gerçek zincirindeki 150.904 ad geçişiyle benzetim yaptık; incelemeciyi veri etiketi temsil etti. Yalnız ada dayalı kararın hata oranı 0,100'dü. Çelişkide daraltma, kararı baştan dar bir alanda geçerli

saymaya göre %48 daha az soru sordu. Sessiz hata (sormadan verilen yanlış karar) farkı geçiş başına 0,008'di. İfta'nın 205.514 geçişinde sonuç %32 ve 0,003'tü. Defter henüz motorda yok.

Kod çalışmasında, "kod neden böyle?" sorularına doğruluk kodla %0 ile %4, karar defteriyle %88 ile %100 oldu: 12 soru, ikişer koşu. İnsan kararlarıyla kimlik tekrar kullanımını sınayacağız.

Aynı önerilerde karşılaştırma

Alperen'in önerdiği karşılaştırmanın ölçülen satırlarını mevcut koşulardan hesapladık: 300 hadis, yalnız şema verilen model, İfta etiketleri, esnek eşleştirme. Son satır kişi gerektiriyor; henüz ölçmedik. Precision, kabul edilenlerin doğru olan payı; recall, doğru cevapların ne kadarını bulduğumuzdur.

Adım	Precision / Recall / F1	Not
1. Yalnız model	0,914 / 0,868 / 0,890	İnceleme yok.
2. + şema kontrolü	Değişmiyor	Haiku koşularında 910 çağrıda tanımsız tip çıkmadı; bir tanımsız özellik çıktı.
3. + alıntı kaynakta mı kontrolü	Değişmiyor	Hiçbir şey işaretlemedi.
4. + değer alıntıda mı kontrolü	0,985 / 0,849 / 0,912	İncelemesiz kabul edilenler; 155 öneri incelemeye gider.
5. + insan incelemesi	Henüz ölçülmedi	Kişi gerekiyor.

Recall biraz düşüyor çünkü işaretlenen öneriler silinmeden inceleme bekliyor. İnsan etiketleriyle yanlış önerileri, tamamen doğru zincirlerin payını, kişiye gönderilenleri ve kişinin değiştirdiklerini ölçeceğiz.

Ne olursa haksız çıkarız

Kontrol, insan etiketlerine göre az hata yakalarsa veya güven skoru aynı inceleme payında aynı sayıda hata yakalarsa fark iddiamız desteklenmez.

Yahya Efe Kuruçay · Deniz Büyükşahin · Alperen Ulukaya · Danışman: Arş. Gör. Dr. Taha Yiğit Alkan

16 Ekim toplantısı: gündem ve kararlar

2 Ekim'den beri yaptıklarımız

1. toplantıda verilen edebiyat taramalarından Alperen'in listesi (graf yapıları, 27 makale) ve Efe'nin listesi (LLM değerlendirme ölçütleri, 38 makale) ortak Zotero kütüphanesinde. 9 Ekim'de benzer projelerden nerede ayrıldığımızı konuşmuştuk. Hadis çalışmalarını ve genel bilgi grafı (kişileri ve bağlantıları tutan yapı) tarafındaki 29 çalışmayı inceledik. Fark iddiamızı daralttık.

Proje önerisinin son metnini hazırladık. Tez ve makale taslaklarını İngilizce ve Türkçe yazdık. TÜBİTAK form taslağını ve hadis uzmanına vereceğimiz notları hazırladık. Kod, veri ve belgeleri tek özel depoda topladık. Ortak Zotero kaynak kütüphanesi kurduk. Bu belgeler henüz sizin tarafınızdan okunmadı.

Riskler

Henüz insan etiketimiz yok; uzmanla görüşmedik. İfta ve AR-Sanad etiketlerinin lisanslarını yazılı olarak doğrulatmadık. Etiketleri ölçüm için kullanıyoruz, yeniden dağıtmıyoruz.

Sizden istediğimiz kararlar

1. Kişinin kararını saklama, kaynaktan yeniden çıkarılabileni yeniden çıkarma iddiasını ve kimlik kararları ile kod soruları üzerine iki destekleyici çalışmayı öneride tutalım mı?
2. Basılı kopyası ekteki CSE 491 proje önerisini mevcut haliyle 18 Ekim 2026'da sunabilir miyiz?
3. Arapça metni Sanadset'ten, İfta ve AR-Sanad etiketlerini dağıtmadan sadece ölçüm için almamız uygun mu?
4. İş planının 10. ve 11. haftalarını yeni geliştirme yerine mevcut kodu inceleme, bir incelemeciyle test ve etiketleme olarak yazmamız uygun mu?
5. Sizi ve ders asistanını özel depoya eklemek için GitHub kullanıcı adınızı alabilir miyiz (bağlantıyı 10. haftada Teams'e koyacağız)?
6. TÜBİTAK 2209-A çağrısı açılınca formu bu çerçeveyle gönderelim mi (danışman onayı e-bideb üzerinden veriliyor)?

Önümüzdeki iki hafta

Uzmanla görüşüp etiketleme kılavuzunun v1 sürümünü tamamlayacağız. 6. haftada mimariyi, veri modelini ve üç ekran taslağını hazırlayacağız.

Ablation tablosunu, yani parçaları çıkarıp katkılarını karşılaştırdığımız tabloyu hazırlayacağız. "Peygamber ravi değildir" kuralını ekleyeceğiz. Etiketlemeye başlayacağız. Üçüncü toplantıyı 6. veya 7. haftada yapmayı planlıyoruz.

2. toplantının formunun bugün imzalanmasını istiyoruz; Teams'e son yükleme günü 16 Ekim.

Yahya Efe Kuruçay · Deniz Büyükşahin · Alperen Ulukaya · Danışman: Arş. Gör. Dr. Taha Yiğit Alkan